

近期工作汇报—套娃实验进展

姚凯方 2026.06.14

实验目的

- 1. 将MRL思想应用在图对比学习上面
- 2. 针对具体的对比学习方法，实现对MRL思想的增强
- (参考MED-MRL思想应用到知识图谱的三种机制)

Baseline实验1—DGI, DGI_MRL

- DGI: 将全图提取出一个概括向量 $\vec{s}$, 让每个节点向量和 $\vec{s}$ 互信息最大化

$$\mathcal{L}_{dgi} = \frac{1}{N+M} \left(\sum_{i=1}^N [\log(\mathcal{D}(\vec{h}_i, \vec{s}))] + \sum_{j=1}^M [\log(1 - \mathcal{D}(\vec{h}_j, \vec{s}))] \right)$$

-
- 假设一个图有三个节点, 每个节点四个维度表示
- dim0 dim1 dim2 dim3
- 节点0: [0.8, 0.1, 0.5, 0.3] $\leftarrow h_0$
- 节点1: [0.2, 0.9, 0.4, 0.7] $\leftarrow h_1$
- 节点2: [0.6, 0.3, 0.8, 0.2] $\leftarrow h_2$
- 那么这个 $\vec{s}$ 就是每个维度求平均, 再用sigmoid函数
- $\vec{s} = \text{sigmoid}([0.533, 0.433, 0.567, 0.400]) = [0.630, 0.607, 0.638, 0.599]$
- $D(h, s) = h \cdot W \cdot s$ 是 h 和这个 s 的匹配程度, 目的就是让真图和 s 尽可能匹配, 假图和 s 尽可能不匹配
- DGI_MRL:就是用不同的维度表示各个节点和全局向量, 然后对各个维度求加权平均值

Baseline实验2—CCASSG, CCASSG_MRL

CCA-SSG

$$\mathcal{L} = \mathcal{L}_{inv} + \lambda \mathcal{L}_{dec}$$

$$\mathcal{L}_{inv} = \|\tilde{\mathbf{Z}}_{\mathbf{A}} - \tilde{\mathbf{Z}}_{\mathbf{B}}\|^2$$

生成了两个随机视图，这一项损失是两个视图的向量的差异，向量表示每个维度的差的平方的和


$$\mathcal{L}_{dec} = \|\tilde{\mathbf{Z}}_{\mathbf{A}}^T \tilde{\mathbf{Z}}_{\mathbf{A}} - I\|^2 + \|\tilde{\mathbf{Z}}_{\mathbf{B}}^T \tilde{\mathbf{Z}}_{\mathbf{B}} - I\|^2$$

- 前一项是减少两个图中对于一个节点表示的差异的
- 后一项是减少不同维度的冗余度的

Baseline实验3—GRACE, GRACE_MRL

$$\ell(\mathbf{u}_i, \mathbf{v}_i) = \log \frac{e^{\theta(\mathbf{u}_i, \mathbf{v}_i)/\tau}}{e^{\theta(\mathbf{u}_i, \mathbf{v}_i)/\tau} + \sum_{k=1}^N \mathbb{1}_{[k \neq i]} e^{\theta(\mathbf{u}_i, \mathbf{v}_k)/\tau} + \sum_{k=1}^N \mathbb{1}_{[k \neq i]} e^{\theta(\mathbf{u}_i, \mathbf{u}_k)/\tau}},$$

- $\text{loss} = l(u,v) + l(v,u)$ 求和取平均
- 生成的两个视图分别为u和v，让两个图中同一个节点靠近，两个视图中的其他节点都是负样本
- Mrl就是使用不同维度表示全图节点，余下内容同理




分母的三项对应的节点对类型 (以任意节点对 (u_i, v_j) 为中心)

① 第一项:

两个视图中每对对应的节点对
(跨视图的“匹配”对)

定义: 两个视图中索引相同的节点配对。



示例节点对:


(u_1, v_1) (u_2, v_2) (u_3, v_3) ...

对应数量: $|U|$ (即 n_1^{**})

② 第二项:

两个视图中没有对应的节点对
(跨视图的“非匹配”对)

定义: 跨视图但索引不同的节点配对。



示例节点对 (以 u_1 为例):


(u_1, v_2) (u_1, v_3) (u_1, v_4) ...

对应数量: $|U|(|V|-1)$ (即 n_{*j})

③ 第三项:

同一个视图中的不同节点对
(同视图的非自环对)

定义: 在同一视图内, 任意两个不同节点的配对 (不含自身)。



示例节点对 (以 U 视图为例, 以 u_1 为例):

(u_1, u_2) (u_1, u_3) (u_1, u_4) ...

对应数量: $C(|U|, 2) = |U|(|U|-1)/2$ (即 n_{**})

分母的三项合计对应的节点对总数:

$$|U| + |U|(|V|-1) + |U|(|U|-1)/2$$

将MED机制引入图对比学习中

- 互学习机制：相邻维度之间学习效果的互相学习

- 原MED:
$$L_{ML}^{i-1,i} = \sum_{(h,r,t) \in \mathcal{T} \cup \mathcal{T}^-} d_{\delta} \left(s_{(h,r,t)}^{i-1}, s_{(h,r,t)}^i \right), 1 < i \leq n, \quad \mathbf{w}$$

$$\begin{aligned} L_{EI}^i = & - \sum_{(h,r,t) \in \mathcal{T} \cup \mathcal{T}^-} pos_{h,r,t}^i \cdot y \log \sigma(s_{(h,r,t)}^i) \\ & + neg_{h,r,t}^i \cdot (1 - y) \log(1 - \sigma(s_{(h,r,t)}^i)), \end{aligned} \quad (5)$$

$$L = \sum_{i=2}^n L_{ML}^{i-1,i} + \sum_{i=1}^n \exp\left(\frac{w_3 \cdot d_i}{d_n}\right) \cdot L_{EI}^i, \quad (6)$$

如何将MED机制引入到图对比学习中?

- 观察发现MED的三种机制中，互学习和进化提升机制的核心都和每个维度学习效果有关，也就是对应MED中的 $s(h,r,t)$ 这个变量，在知识图谱中这个 s 就是判断这个三元组匹配度打分，而对于自监督对比学习中并不存在一个能够表示这个维度学习效果的量
- 因此，需要找到一个量来表示这个维度下的学习效果

我的打分函数—State，这个维度下，学的到底多烂

目前打算是在GRACE的基础上引入MRL以及MED这样的框架

$$\mathcal{L}_{total} = \sum_{i=2}^{|M|} \mathcal{L}_{ML}^{i-1,i} + \sum_{i=1}^{|M|} e^{\frac{\lambda M_i}{M_{max}}} \mathcal{L}_{EI}^i$$

$$\mathcal{L}_{ML}^{i-1,i} = \sum_{j=1}^{|G|} |State_{i-1,j} - State_{i,j}|$$

$$\mathcal{L}_{EI}^i = \sum_{j=1}^{|G|} w_j^i \frac{[l(u_{i,j}, v_{i,j}) + l(v_{i,j}, u_{i,j})]}{2}$$

$$w_j^i = \frac{e^{State_{i-1,j}}}{\sum_{k=1}^{|G|} e^{State_{i-1,k}}}$$

$$l(u_{i,j}, v_{i,j}) = \log \frac{e^{\frac{\theta(u_{i,j}, v_{i,j})}{\tau}}}{e^{\frac{\theta(u_{i,j}, v_{i,j})}{\tau}} + \sum_{k=1}^{|G|} \mathbb{1}_{[k \neq j]} e^{\frac{\theta(u_{i,j}, v_{i,k})}{\tau}} + \sum_{k=1}^{|G|} \mathbb{1}_{[k \neq j]} e^{\frac{\theta(u_{i,j}, u_{i,k})}{\tau}}}$$

$$State_{i,j} = \frac{1}{2} [2 - p(u_{i,j}, v_{i,j}) - p(v_{i,j}, u_{i,j})]$$

$$p(u_{i,j}, v_{i,j}) = \frac{e^{\frac{\theta(u_{i,j}, v_{i,j})}{\tau}}}{e^{\frac{\theta(u_{i,j}, v_{i,j})}{\tau}} + \sum_{k=1}^{|G|} \mathbb{1}_{[k \neq j]} e^{\frac{\theta(u_{i,j}, v_{i,k})}{\tau}} + \sum_{k=1}^{|G|} \mathbb{1}_{[k \neq j]} e^{\frac{\theta(u_{i,j}, u_{i,k})}{\tau}}}$$

- 目前的设想是将第一个公式作为最后的loss
- P：可以看成是对两个视图中的节点进行配对，两个视图中对应的同一个节点配对成功的概率，范围是[0,1)
- State：学习得越好打分应该越高，p越高，1-p就可以认为学习程度有多差劲，仿照GRACE的loss的对称性，使用p(u,v)和p(v,u)一起求平均
- 其实这个形式不是很重要，因为维度间相减可以抵消的，所以是1-p还是p都可以，结果是相同的

- 考虑到之后也需要做消融实验就打算一步一步增加，目前先加入Mutual Learning：

$$\mathcal{L}_{total} = \alpha \sum_{i=2}^{|M|} \mathcal{L}_{ML}^{i-1,i} + \beta \sum_{i=1}^{|M|} \mathcal{L}_{GRACE}^i$$

$$\mathcal{L}_{ML}^{i-1,i} = \sum_{j=1}^{|\mathcal{G}|} \frac{|State_{i-1,j} - State_{i,j}|}{|\mathcal{G}|}$$

$$\mathcal{L}_{GRACE}^i = \sum_{j=1}^{|\mathcal{G}|} \frac{[l(u_{i,j}, v_{i,j}) + l(v_{i,j}, u_{i,j})]}{2|\mathcal{G}|}$$

alpha beta都是超参数，

设定互学习的影响权重

先保留GRACE的原始损失

l代表维度，j代表节点

$$l(u_{i,j}, v_{i,j}) = \log \frac{e^{\frac{\theta(u_{i,j}, v_{i,j})}{\tau}}}{e^{\frac{\theta(u_{i,j}, v_{i,j})}{\tau}} + \sum_{k=1}^{|\mathcal{G}|} \mathbb{1}_{[k \neq j]} e^{\frac{\theta(u_{i,j}, v_{i,k})}{\tau}} + \sum_{k=1}^{|\mathcal{G}|} \mathbb{1}_{[k \neq j]} e^{\frac{\theta(u_{i,j}, u_{i,k})}{\tau}}}$$

$$State_{i,j} = \frac{1}{2} [2 - p(u_{i,j}, v_{i,j}) - p(v_{i,j}, u_{i,j})]$$

$$p(u_{i,j}, v_{i,j}) = \frac{e^{\frac{\theta(u_{i,j}, v_{i,j})}{\tau}}}{e^{\frac{\theta(u_{i,j}, v_{i,j})}{\tau}} + \sum_{k=1}^{|\mathcal{G}|} \mathbb{1}_{[k \neq j]} e^{\frac{\theta(u_{i,j}, v_{i,k})}{\tau}} + \sum_{k=1}^{|\mathcal{G}|} \mathbb{1}_{[k \neq j]} e^{\frac{\theta(u_{i,j}, u_{i,k})}{\tau}}}$$

进展0:代码改进

- 之前是训练五次 全图推理五次 分类头训练五次，并且只存储结果
- 现在是训练一次 全图推理一次 分类头训练五次，存储最终正确率的同时，模型参数文件也会存储起来
- 重跑第一次😭

进展1:寻找合适的数据集

- 数据集
 - 旧版: Cora, obgn-arxiv, obgn-products
 - 由于Cora数据集过小, 而MRL目的就是解决大规模推理计算量的问题, 包括实测增加互学习的效果不佳, 改为使用obgn-mag
 - obgn-arxiv, obgn-products, obgn-mag
 - 使用大图跑实验均需要使用batch-norm做归一化, 之前的代码没有归一化, 所以正在重新跑, 重跑第二次😭

按照方法分类

但是都没做 batch norm

按照数据分类

	32	64	128	256	384	512	768
GCN_Cora	0.7690 +- 0.000000	0.7990 +- 0.000000	0.7590 +- 0.000000	0.7910 +- 0.000000	0.8070 +- 0.000000	0.7900 +- 0.000000	0.7940 +- 0.000000
GCN_Arxiv	0.6620 +- 0.000000	0.6737 +- 0.000000	0.6722 ± 0.000000	0.6886 ± 0.000000	0.6736 ± 0.000000	0.6838 +- 0.000000	0.6228 +- 0.000000
GCN_Products	0.6980+-0.000000	0.7247 +- 0.000000	0.7252 +- 0.000000	0.7222 +- 0.000000	0.7124 +- 0.000000	0.6886 +- 0.000000	0.7317 +- 0.000000
DGI_Cora	0.6794 +- 0.000028	0.7486 +- 0.000015	0.7878 +- 0.000023	0.8106 +- 0.000011	0.8166 +- 0.000011	0.8242 +- 0.000001	0.8272 +- 0.000000
DGI_Arxiv	0.5642 +- 0.000004	0.6148 +- 0.000006	0.6323 +- 0.000002	0.6455 +- 0.000002	0.6499 +- 0.000001	0.6538 +- 0.000001	0.6561 +- 0.000001
DGI_Products	0.5078 +- 0.000003	0.5781 +- 0.000001	0.6170 ± 0.000002	0.6535 +- 0.000003	0.6641 +- 0.000001	0.6657 +- 0.000001	0.7074 +- 0.000009
DGI_MRL_Cora	0.7180 +- 0.000012	0.7734 +- 0.000014	0.7992 +- 0.000040	0.8130 +- 0.000004	0.8278 +- 0.000004	0.8300 +- 0.000010	0.8278 +- 0.000009
DGI_MRL_Arxiv	0.5419 +- 0.000000	0.5911 +- 0.000001	0.6182 +- 0.000001	0.6362 +- 0.000000	0.6451 +- 0.000003	0.6501 +- 0.000001	0.6566 +- 0.000002
DGI_MRL_Products	0.5594 +- 0.000002	0.6171 +- 0.000001	0.6522 +- 0.000003	0.6834 +- 0.000003	0.6973 +- 0.000001	0.7044 +- 0.000003	0.7112 +- 0.000002
CCA_SSG_Cora	0.6898 +- 0.000004	0.7372 +- 0.000016	0.7838 +- 0.000001	0.8252 +- 0.000001	0.8328 +- 0.000088	0.8400 +- 0.000006	0.8326 +- 0.000000
CCA_SSG_Arxiv	0.5433 +- 0.000000	0.6246 +- 0.000000	0.6594 +- 0.000004	0.6843 +- 0.000002	0.6925 +- 0.000001	0.6950 ± 0.000003	0.6963 +- 0.000003
CCA_SSG_Products	0.5498+-0.000002	0.6380 ± 0.000004	0.6713+-0.000004	0.6948 ± 0.000005	0.7150 +- 0.000016	0.7259 +- 0.000021	0.7416 ± 0.000027
CCA_SSG_MRL_Cora	0.7502 +- 0.000106	0.8060 +- 0.000006	0.8148 +- 0.000076	0.8320 +- 0.000026	0.8436 +- 0.000000	0.8376 +- 0.000000	0.8406 +- 0.000001
CCA_SSG_MRL_Arxiv	0.6353 +- 0.000000	0.6606 +- 0.000000	0.6741 +- 0.000000	0.6864 +- 0.000002	0.6905 +- 0.000007	0.6923 +- 0.000009	0.6989 +- 0.000001
CCA_SSG_MRL_Products	0.6837 +- 0.000001	0.7019 +- 0.000005	0.7222 +- 0.000002	0.7391 +- 0.000006	0.7439 +- 0.000001	0.7494 +- 0.000009	0.7507 +- 0.000033
GRACE_Cora	0.5312 +- 0.000317	0.7070 +- 0.000122	0.7420 +- 0.000012	0.7976 +- 0.000001	0.8284 +- 0.000002	0.8218 +- 0.000000	0.8244 +- 0.000001
GRACE_Arxiv	0.6606 +- 0.000000	0.6761 +- 0.000001	0.6857 +- 0.000001	0.6897 +- 0.000000	0.6979 +- 0.000000	0.6971 +- 0.000000	0.6975 +- 0.000001
GRACE_Products	0.5913+-0.000009	0.6428+-0.000005	0.6749 +- 0.000015	0.6889 +- 0.000002	0.7068 +- 0.000017	0.7668 +- 0.000020	0.7641 +- 0.000022
GRACE_MRL_Cora	0.7732 +- 0.000004	0.7926 +- 0.000016	0.7922 +- 0.000137	0.8026 +- 0.000004	0.8082 +- 0.000071	0.8166 +- 0.000000	0.8194 +- 0.000000
GRACE_MRL_Arxiv	0.4867 +- 0.000001	0.5693 +- 0.000000	0.6460 +- 0.000001	0.6832 +- 0.000000	0.6946 +- 0.000000	0.6992 +- 0.000001	0.7040 +- 0.000000
GRACE_MRL_Products	0.4300 +- 0.000000	0.5098 +- 0.000002	0.6069 +- 0.000002	0.6981 +- 0.000002	0.7194 +- 0.000002	0.7257 +- 0.000002	0.7302 +- 0.000001
GRACE_ML_MRL_Cora	0.7498 +- 0.000079	0.7718 +- 0.000071	0.7838 +- 0.000049	0.7888 +- 0.000052	0.7926 +- 0.000000	0.7962 +- 0.000000	0.8020 +- 0.000000
GRACE_ML_MRL_Arxiv	0.6001 +- 0.000001	0.6705 +- 0.000000	0.6956 +- 0.000000	0.7036 +- 0.000000	0.7049 +- 0.000002	0.7058 +- 0.000000	0.7054 +- 0.000003
GRACE_ML_MRL_Products	0.4659 +- 0.000001	0.5864 +- 0.000002	0.6777 +- 0.000013	0.7374 +- 0.000037	0.7421 +- 0.000002	0.7542 +- 0.000027	0.7495 +- 0.000019
	32	64	128	256	384	512	768
GCN_Cora	0.7690 +- 0.000000	0.7990 +- 0.000000	0.7590 +- 0.000000	0.7910 +- 0.000000	0.8070 +- 0.000000	0.7900 +- 0.000000	0.7940 +- 0.000000
DGI_Cora	0.6794 +- 0.000028	0.7486 +- 0.000015	0.7878 +- 0.000023	0.8106 +- 0.000011	0.8166 +- 0.000011	0.8242 +- 0.000001	0.8272 +- 0.000000
DGI_MRL_Cora	0.7180 +- 0.000012	0.7734 +- 0.000014	0.7992 +- 0.000040	0.8130 +- 0.000004	0.8278 +- 0.000004	0.8300 +- 0.000010	0.8278 +- 0.000009
CCA_SSG_Cora	0.6898 +- 0.000004	0.7372 +- 0.000016	0.7838 +- 0.000001	0.8252 +- 0.000001	0.8328 +- 0.000088	0.8400 +- 0.000006	0.8326 +- 0.000000
CCA_SSG_MRL_Cora	0.7502 +- 0.000106	0.8060 +- 0.000006	0.8148 +- 0.000076	0.8320 +- 0.000026	0.8436 +- 0.000000	0.8376 +- 0.000000	0.8406 +- 0.000001
GRACE_Cora	0.5312 +- 0.000317	0.7070 +- 0.000122	0.7420 +- 0.000012	0.7976 +- 0.000001	0.8284 +- 0.000002	0.8218 +- 0.000000	0.8244 +- 0.000001
GRACE_MRL_Cora	0.7732 +- 0.000004	0.7926 +- 0.000016	0.7922 +- 0.000137	0.8026 +- 0.000004	0.8082 +- 0.000071	0.8166 +- 0.000000	0.8194 +- 0.000000
GRACE_ML_MRL_Cora	0.7498 +- 0.000079	0.7718 +- 0.000071	0.7838 +- 0.000049	0.7888 +- 0.000052	0.7926 +- 0.000000	0.7962 +- 0.000000	0.8020 +- 0.000000
GCN_Arxiv	0.6620 +- 0.000000	0.6737 +- 0.000000	0.6722 ± 0.000000	0.6886 ± 0.000000	0.6736 ± 0.000000	0.6838 +- 0.000000	0.6228 +- 0.000000
DGI_Arxiv	0.5642 +- 0.000004	0.6148 +- 0.000006	0.6323 +- 0.000002	0.6455 +- 0.000002	0.6499 +- 0.000001	0.6538 +- 0.000001	0.6561 +- 0.000001
DGI_MRL_Arxiv	0.5419 +- 0.000000	0.5911 +- 0.000001	0.6182 +- 0.000001	0.6362 +- 0.000000	0.6451 +- 0.000003	0.6501 +- 0.000001	0.6566 +- 0.000002
CCA_SSG_Arxiv	0.5433 +- 0.000000	0.6246 +- 0.000000	0.6594 +- 0.000004	0.6843 +- 0.000002	0.6925 +- 0.000001	0.6950 ± 0.000003	0.6963 +- 0.000003
CCA_SSG_MRL_Arxiv	0.6353 +- 0.000000	0.6606 +- 0.000000	0.6741 +- 0.000000	0.6864 +- 0.000002	0.6905 +- 0.000007	0.6923 +- 0.000009	0.6989 +- 0.000001
GRACE_Arxiv	0.6606 +- 0.000000	0.6761 +- 0.000001	0.6857 +- 0.000001	0.6897 +- 0.000000	0.6979 +- 0.000000	0.6971 +- 0.000000	0.6975 +- 0.000001
GRACE_MRL_Arxiv	0.4867 +- 0.000001	0.5693 +- 0.000000	0.6460 +- 0.000001	0.6832 +- 0.000000	0.6946 +- 0.000000	0.6992 +- 0.000001	0.7040 +- 0.000000
GRACE_ML_MRL_Arxiv	0.6001 +- 0.000001	0.6705 +- 0.000000	0.6956 +- 0.000000	0.7036 +- 0.000000	0.7049 +- 0.000002	0.7058 +- 0.000000	0.7054 +- 0.000003
GCN_Products	0.6980+-0.000000	0.7247 +- 0.000000	0.7252 +- 0.000000	0.7222 +- 0.000000	0.7124 +- 0.000000	0.6886 +- 0.000000	0.7317 +- 0.000000
DGI_Products	0.5078 +- 0.000003	0.5781 +- 0.000001	0.6170 ± 0.000002	0.6535 +- 0.000003	0.6641 +- 0.000001	0.6657 +- 0.000001	0.7074 +- 0.000009
DGI_MRL_Products	0.5594 +- 0.000002	0.6171 +- 0.000001	0.6522 +- 0.000003	0.6834 +- 0.000003	0.6973 +- 0.000001	0.7044 +- 0.000003	0.7112 +- 0.000002
CCA_SSG_Products	0.5498+-0.000002	0.6380 ± 0.000004	0.6713+-0.000004	0.6948 ± 0.000005	0.7150 +- 0.000016	0.7259 +- 0.000021	0.7416 ± 0.000027
CCA_SSG_MRL_Products	0.6837 +- 0.000001	0.7019 +- 0.000005	0.7222 +- 0.000002	0.7391 +- 0.000006	0.7439 +- 0.000001	0.7494 +- 0.000009	0.7507 +- 0.000033
GRACE_Products	0.5913+-0.000009	0.6428+-0.000005	0.6749 +- 0.000015	0.6889 +- 0.000002	0.7068 +- 0.000017	0.7668 +- 0.000020	0.7641 +- 0.000022
GRACE_MRL_Products	0.4300 +- 0.000000	0.5098 +- 0.000002	0.6069 +- 0.000002	0.6981 +- 0.000002	0.7194 +- 0.000002	0.7257 +- 0.000002	0.7302 +- 0.000001
GRACE_ML_MRL_Products	0.4659 +- 0.000001	0.5864 +- 0.000002	0.6777 +- 0.000013	0.7374 +- 0.000037	0.7421 +- 0.000002	0.7542 +- 0.000027	0.7495 +- 0.000019

进展2:新增baseline实验 — PCA SVG

- 将高维度的向量直接通过PCA, SVG手段进行降维, 作为对照组, 展示实验结果
- 目前代码实现已经完成, 但是需要依托dgi ccassg grace的最高维度的参数之后才能跑, 正在跑实验
- 这个直接用最高维度降维跑推理和评估, 不需要再训练了, 所以比较快速的

问题：

- 1. Gcn跑出的结果很奇怪，经常高维度准确率比低维度低，之前觉得可能因为 epoch 不够，但是调整成大 epoch 并且早停，改善了一点，但是还是会出现高维度准确率低的问题

GCN_Arxiv	0.6939 +- 0.000000	0.7034 +- 0.000000	0.6932 +- 0.000000	0.6976 +- 0.000000	0.7011 +- 0.000000	0.6933 +- 0.000000	0.6897 +- 0.000000
GCN_Products	0.7364 ± 0.000000	0.7566 ± 0.000000	0.7584 +- 0.000000	0.7580 +- 0.000000	0.7451 ± 0.000000	0.7621 ± 0.000000	0.7570 ± 0.000000

- 2. 参数控制不好
 - 选取了7个维度：32 64 128 256 384 512 768，跑实验经常是到中间某个大维度就OOM，然后保证每个维度的参数一致，需要重头再来
 - 解决：先跑MRL，保证不会OOM了之后再跑

目前已经跑出来的结果： result.xlsx